

Nome: Tarcísio José Martins Ribeiro Código: 20382

1. (1,0) Utilizando a linguagem R:

- a. Crie um vetor com os pesos dos alunos, considerando os valores a seguir:
52 52 54 56 57 60 61 65 70 120

p_a = c(52, 52, 54, 56, 57, 60, 61, 65, 70, 120)

- b. Exibir o vetor, considerando todas as posições;

p_a

- c. Exibir apenas da primeira posição (o peso da primeira pessoa);

p_a[1]

- d. Exibir apenas a décima posição (o peso da décima pessoa);

p_a[10]

- e. Exibir a quantidade de posições do vetor;

length(p_a)

- f. Calcule a média dos pesos, sem utilizar a função nativa *mean()*;

```
"m" = function(v_p_a)
{
  media = 0
  for (i in 1:length(v_p_a))
  {
    media = media + v_p_a[i]
  }
  media = media/length(v_p_a)
  media
}
m(p_a)
```

- g. Calcule a mediana dos pesos.

median(p_a)

2. (1,5) A linguagem R não possui uma função nos pacotes padrões para calcular a moda. Elabore uma função em R, responsável pelo cálculo da moda. Na sequência, calcule a moda do vetor de pesos dos alunos, criado no item (1).

```
"md" = function(v_p_a) {
  print(names(sort(-table(as.vector(v_p_a)))[1]))
}
md(p_a)
```

3. (1,5) Utilizando a linguagem R:

a. Crie dois vetores, denominados *turma_1* e outro *turma_2*, com os seguintes valores:

```
turma_1: 75.02786847, 56.51450656, 55.57517955, 62.00893933, 82.82022277,
91.78076684, 71.53028442, 82.22315417, 71.14621041, 76.27644453
turma_2: 63.96213546, 51.00946728, 54.48449137, 53.62955058, 61.62138863,
59.99119596, 57.61297576, 62.52220793, 64.54041384, 63.95477107
```

```
turma_1 = c(75.02786847, 56.51450656, 55.57517955, 62.00893933,
82.82022277, 91.78076684, 71.53028442, 82.22315417,
71.14621041, 76.27644453)
```

```
turma_2 = c(63.96213546, 51.00946728, 54.48449137, 53.62955058,
61.62138863, 59.99119596, 57.61297576, 62.52220793,
64.54041384, 63.95477107)
```

b. Calcule a média da turma 1 e 2, exibindo as seguintes mensagens, para

cada vetor: Média da turma 1: 72.490357705

Média da turma 2: 59.332859788

```
m_1 = paste("Média da turma 1: ", mean(turma_1))
m_1
m_2 = paste("Média da turma 2: ", mean(turma_2))
m_2
```

c. Calcule a amplitude da *turma_1* e *turma_2*.

```
diff(range(turma_1))
diff(range(turma_2))
```

4. (1,0) Considere a criação de dois vetores, por meio da linguagem R, ora nomeados de **cardapio** e **precos**, com as respectivas estruturas abaixo:

```
cardapio (Filé à parmegiana, Feijoada, Batatas Fritas, Lasanha à Bolonhesa, Salada Caprese)
precos (32.50, 44.00, 12.00, 35.50, 27.00)
```

A partir da criação dos vetores acima, e, fazendo uso de uma função específica da linguagem R, relacione adequadamente os vetores **cardapio** e **preco**, criando dessa forma uma estrutura similar a uma tabela relacional.

```
cardapio = c('File a Parmegiana', 'Feijoada', 'Batatas Fritas', 'Lasanha a
Bolonhesa', 'Salada Caprese')
precos = c(32.50, 44.00, 12.00, 35.50, 27.00)
```

```
cardapio.preco = data.frame(cardapio, precos)  
cardapio.preco
```

5. (1,5) Indique o código R para efetuar as seguintes operações:

a. Criar uma matriz com duas linhas e três colunas, com os números inteiros de 1 a 6

```
matriz = matrix(1:6,2, 3 )  
matriz
```

b. Identificar a linha 2 e a coluna 3 da matriz

```
matriz[2,3]
```

c. Verificar as dimensões da matriz

```
dim(matriz)
```

d. Calcular a soma dos elementos da matriz

```
sum(matriz)
```

e. Calcular a soma dos elementos da linha 1

```
sum(matriz[1,])
```

f. Criar um vetor cujos elementos sejam as médias dos valores de cada coluna

```
m = c(mean(matriz[,1]),mean(matriz[,2]),mean(matriz[,3]))
```

6. (1,5) Indique o código R para efetuar as seguintes operações:

a. Definir duas matrizes: a matriz A com dimensões 2x3 e com o valor 2 em todas as células e a matriz B com dimensões 2x3 e os valores entre 1 e 6.

```
A = matrix(2, 2, 3)  
A  
B = matrix(1:6, 2, 3)  
B
```

b. Calcular A + B (com o operador aritmético +).

```
A + B
```

c. Alterar as dimensões da matriz B para que fique com 3x2.

```
dim(B) = c(3, 2)
```

d. Calcular a multiplicação de A por B.

AB**

7. (1,0) Indique o código R para efetuar as seguintes operações:

a. Definir uma variável nomeada de *lista* como uma *list* com dois campos: nome = “João” e idade = 30.

**lis = list(n = "João", idade = 30)
lis**

b. Verificar o conteúdo de *lista*, exibindo o campo *nome* e *idade* com \$ e [[]].

**lis\$nome
lis[[1]]
lis\$idade
lis[[2]]**

8. (1,0) Uma série de procedimentos de pré-processamento de dados é aplicada a um conjunto de dados advindo de um processo hipotético de entrevistas realizadas com *chefs* de restaurantes. O objetivo aqui é ilustrar algumas estratégias de pré-processamento apresentadas em sala de aula. Suponha uma pesquisa realizada com 11 *chefs*, na qual lhes foram feitas perguntas sobre dados pessoais, sobre seu trabalho e sobre o restaurante onde trabalha. Os seguintes atributos descritivos referentes ao contexto de trabalho de cada um dos chefs foram obtidos:

- a. Idade: valores inteiros, entre 18 (maioridade) e 90;
- b. Salário: valores reais entre 0 e 30.000 mensais;
- c. Formação: nenhuma, fundamental, médio, superior, pós-graduação;
- d. Carga horária de trabalho: valores reais entre 1 e 8 horas diárias;
- e. Quantidade de pratos sob sua responsabilidade: valores inteiros entre 1 e 30;
- f. Responsabilidade sobre a carta de vinhos: sim ou não;
- g. Capacidade do restaurante: valores inteiros entre 4 a 500 (pessoas);
- h. Localização do restaurante: aeroportuário, bairro, centro, portuário, rodoviário, zona rural; i. Tipo de cardápio: argentino, (especializado em) carnes, espanhol, francês, internacional, italiano, mediterrâneo, mexicano, oriental, (especializado em) pizzas, português, regional;
- j. Lucratividade do restaurante: valores reais entre -100.000 a 100.000 mensais;
- k. Saldo mensal: positivo (+) ou negativo (-) (derivado da lucratividade do restaurante).

A partir das respostas obtidas, foi possível organizar um conjunto de dados em que cada *chef* é considerado um exemplar, as perguntas são os atributos descritivos, e as respostas recebidas são os valores atribuídos a cada atributo. As respostas foram organizadas em uma base de dados, como apresentado na Tabela 1. Um resumo referente a uma análise preliminar sobre a base de dados leva às informações ilustradas no Quadro 1.

Tabela 1 – Base de dados *Chefs*

ID	Idade	Salário	Formação	carga-horária	Qtde pratos	Vinhos	Capacidade	Localização	Tipo cardápio	Lucratividade	Saldo
1	45	7.000,00	superior	8,0	15	não	100	portuário	mediterrâneo	30.000,00	+
2	48	30.000,00	pós-graduação	8,0	25	sim	100	portuário	espanhol	150.000,00	+
3	31	7.500,00	superior	8,0	10	não	70	centro	oriental	-15.000,00	-
4	40	8.000,00	médio	6,0	15	não	80	aeroportuário	argentino	50.000,00	+
5	25	8.000,00	superior	6,0	18	não	300	rodoviário	carnes	70.000,00	+
6	75	??	superior	6,0	23	não	150	centro	italiano	50.000,00	+
7	43	15.000,00	pós-graduação	8,0	20	sim	100	bairro	francês	70.000,00	+
8	29	7.000,00	médio	8,0	13	sim	35	centro	argentino	30.000,00	+
9	50	8.500,00	superior	??	12	sim	50	bairro	mexicano	-2.000,00	-
10	51	15.000,00	superior	6,0	16	não	1	bairro	internacional	10.000,00	+
11	39	3.000,00	médio	4,0	10	não	50	zona rural	Regional	10.000,00	+

Quadro 1 – Resumo da base de dados Chefs

Quantidade de exemplares: 11				
Valores ausentes	Sim		Valores ruidosos	Sim
Valores inconsistentes	Sim		Redundância de dados	Sim

Quantidade de atributos: 12				
• identificadores	1		descritivos	11
			• quantitativos discretos	3
			• quantitativos contínuos	3
			• qualitativos nominais	4
			• qualitativos ordinais	1

Analisando o Quadro 1, verifica-se a necessidade de pré-processamento para correção de alguns problemas. Segundo esse quadro, há valores ausentes, inconsistentes, ruidosos e redundantes. Porém, o pré-processamento deve ser aplicado com cuidado, pois não se pode incorrer no erro de descaracterizar o contexto real. Assim, segue a discussão sobre cada um dos problemas apontados no Quadro 1.

- **Problema 1 - valores ausentes:** os exemplares com ID 6 e 9 apresentam valores ausentes, respectivamente, nos atributos “salário” e “carga horária”. A remoção desses exemplares não é uma boa solução, pois o conjunto de dados já é muito pequeno em relação à quantidade de exemplares. Note, ainda, que remover o exemplar 9 é remover um dos dois exemplares que apresentam lucratividade negativa, ou seja, corre-se o risco de se perder uma valiosa informação sobre o contexto em análise. Preencher os valores manualmente seria possível, a partir de um retorno do entrevistado, porém, nem sempre é viável. O preenchimento automático pode ser uma solução, usando medidas estatísticas. Um estudo sobre a distribuição dos valores em cada atributo deveria ser feito, a fim de analisar a adequabilidade do preenchimento por meio dessas medidas.
- **Problema 2 – valores ruidosos:** por meio de uma inspeção visual, percebe-se que o valor do atributo “salário”, para o exemplar com ID 2, precisa ser analisado com mais cuidado, pois pode representar um *outlier*. O valor 30.000,00, embora dentro do intervalo de valores esperado, está um pouco distante de todos os demais valores assumidos por esse atributo na base de dados. A análise deste caso pode influenciar o tratamento dado aos valores ausentes. Se esse valor realmente representar um *outlier*, uma decisão deverá ser tomada sobre considerá-lo um ruído e alterá-lo, deslocando-o para dentro da distribuição dos demais valores, ou mantê-lo, entendendo que, de fato, esse é o único *chef* na amostra que consegue chegar a esse salário. A depender da decisão tomada, o conjunto de valores para cálculo da medida estatística usada para preenchimento do valor ausente no atributo pode mudar.

Diante das discussões apresentadas, é preciso tomar algumas decisões a fim de pré-processar os

dados para construir um conjunto de dados que possa ser processado por algoritmos de mineração. Dessa forma, escolha alternativas corretas para adequar os valores ausentes (problema 1) e os valores ruidosos (problema 2).

Para o problema 1, a solução seria através do cálculo da média ou mediana, encontrar os valores que melhor se encaixa para a situação problema, de forma a completar os campos vazios. Para o problema 2, antes de tudo, determinaria se realmente classifica-se como um outlier o salário de R\$ 30.000, e após essa decisão, realizaria a filtragem, se necessário.